Protocolo E1 — Área Educación

v1.0: 7 de octubre de 2026 (Martín Soto) · v1.1: 15 de octubre de 2026

1. Equipo y roles

Este protocolo cubre la entrega E1 (semana 1, 10 %) del área Educación: protocolo, registro de búsqueda, universo exportado, script de muestreo y lista ordenada.

Integrante	RUT	Correo	Rol E1	Iniciales (A08)
Martín Eduardo Soto Cabezas	20.953.559-9	martin.soto.01@alumnos.ucm.cl	Coordinador de datos; codificador	MSC
Juan Pablo Maureira Sanhueza	21.134.929-8	juan.maureira@alumnos.ucm.cl	Coordinador de codificación y confiabilidad; codificador	JPM

- Coordinador de datos (integridad de la base, registro de búsqueda, repositorio): Martín Eduardo Soto Cabezas (MSC). Descarga y exporta las bases de WoS, mantiene el repositorio y ejecuta los scripts. JPM coordina la codificación y la confiabilidad: calibración, bitácora de desacuerdos, libro de códigos y cálculo de concordancia. Ambos son codificadores.
- Roles CRediT iniciales: Conceptualization y Methodology (equipo + Dr. José Alejandro González Campos); Data curation y Software (MSC, coordinador de datos); Validation y Formal analysis (JPM, coordinador de codificación); Investigation (ambos codificadores); Writing – original draft y Writing – review & editing (ambos).
- Versión del protocolo: 1.1 (15 de octubre de 2026). Todo cambio posterior se registra con fecha y justificación en docs/bitacora_decisiones.md. Cambios respecto de la 1.0: roles y coordinador de datos; registro de búsqueda; nombres de los lotes y salidas del script; estructura del repositorio; estado de las decisiones abiertas; declaración de IA.

2. Objetivo y preguntas

Estimar qué funciones asume la IA generativa en la producción de artículos originales de Educación indexados en WoS (2025-2026) y con qué transparencia se declaran. La IA se estudia como herramienta de autoría, no como tema.

1. RQ1 (prevalencia): proporción de artículos que declaran uso de IA y proporción que declara no usarla.
2. RQ2 (determinantes): asociación de año, editorial, cuartil, acceso abierto, región, lengua oficial del país de correspondencia, colaboración internacional y política editorial con la declaración.
3. RQ3 (funciones y profundidad): usos declarados (bloque F), D_IA y A_IA.
4. RQ4 (transparencia): distribución y determinantes de Q_IA.
5. RQ5 (perfiles): perfiles de uso por clases latentes o ACM.

Foco específico de Educación: uso de IA en análisis cualitativo (F10 en estudios con XE3 = 2 o 5) y en traducción (F03) por autores de países sin inglés como lengua oficial (B19 = 0).

3. Universo y consulta

El universo son los registros de WoS Core Collection (SCIE, SSCI, ESCI), tipo Article, PY 2025-2026, en inglés o español, de las cuatro categorías de Educación.

Consulta (búsqueda avanzada, sin términos de IA para no seleccionar por la variable resultado):

```
WC=("Education & Educational Research" OR "Education, Scientific Disciplines"
OR "Education, Special" OR "Psychology, Educational") AND PY=(2025-2026) AND
DT=(Article) AND LA=(English OR Spanish)
```

Luego se restringe a las ediciones SCIE, SSCI y ESCI (filtro de ediciones de la Core Collection).

Verificación de sintaxis antes de ejecutar (registrar el resultado de cada punto):

- ☑️ WC acepta los nombres de categoría entre comillas, con coma y &, tal como aparecen en el listado de categorías de WoS. Resultado: los 91.185 registros tienen al menos una de las cuatro categorías de Educación.
- ☐ PY=(2025-2026) recupera ambos años; anotar el N por año con el filtro Publication Years. Resultado en los archivos: 2025 = 50.362 y 2026 = 40.823, sin registros fuera de rango. Falta contrastar con el filtro Publication Years de WoS.
- ☑️ Cómo trata WoS los registros Early Access sin año asignado. Resultado: hay 52.420 Early Access y todos traen PY; ninguno quedó sin año.
- ☑️ DT=(Article) incluye registros doble tipo: se exportan igual y se depuran por script. Resultado: Article 91.125; Article; Retracted Publication 39; Article; Proceedings Paper 18; Article; Data Paper 2; Article; Publication with Expression of Concern 1; ningún Review.
- ☐ La misma consulta de Salud y Computación/Ingeniería se ejecuta el mismo día. Pendiente: confirmar con los otros equipos.

4. Registro de búsqueda

Se completa el día de ejecución, una fila por paso; los N salen de la pantalla de resultados de WoS.

Campo	Valor
Fecha y hora (hora de Chile)	8 de octubre de 2026, 21:54 (hora de Chile). Hora de término de la descarga de los lotes; la hora de ejecución de la consulta es anterior y consta en el historial de WoS.
Responsable	Martín Eduardo Soto Cabezas (MSC), coordinador de datos.
Consulta exacta ejecutada	PENDIENTE: copiar desde el historial de búsqueda de WoS.
Ajustes de sintaxis respecto del enunciado	PENDIENTE: si no hubo ajustes, escribir

Campo	Valor
	"ninguno".
Filtros aplicados (ediciones)	SCIE, SSCI, ESCI
N universo total	91.185 (WoS y archivos coinciden).
N 2025	50.362 (archivos). Pantalla de WoS: PENDIENTE.
N 2026	40.823 (archivos). Pantalla de WoS: PENDIENTE.
N por edición (SCIE / SSCI / ESCI)	SCIE 13.970 · SSCI 42.738 · ESCI 40.933 (no excluyentes; suma 97.641).
Formato de exportación	Plain text, Full Record
Número de lotes y rango de registros	100 archivos descargados; 8 eran copias exactas y se descartaron; 92 lotes conservados (91 de 1.000 registros y 1 de 185). Detalle en output/lotes_EDU.csv.
Archivos exportados	data/raw/wos_edu/ (savedrecs.txt, savedrecs (1).txt, …).
Observaciones	Ver docs/registro_busqueda_EDU.md (lotes descartados y observaciones).

5. Exportación del universo

El universo se exporta completo en texto plano (Full Record), en lotes consecutivos, y se guarda sin modificar.

- Formato: Plain text file, contenido Full Record (incluye UT, PY, DT, LA, WC). Excel también lo lee el script, pero se usa un solo formato para todo el universo.
- Lotes: WoS limita el número de registros por exportación (verificar el máximo vigente). Se exporta por rangos consecutivos sin saltos ni solapes: 1-1000, 1001-2000, etc.
- Nombres: los que entrega WoS (savedrecs.txt, savedrecs (1).txt, …), sin renombrar, en data/raw/wos_edu/. output/lotes_EDU.csv guarda el nombre, el número de registros y la huella md5 de cada lote.
- Control: la suma de registros de los lotes debe coincidir con el N total del registro de búsqueda; el script lo informa.
- Los archivos crudos no se editan; toda depuración ocurre en el script.

6. Depuración y muestreo (componente A)

El script `R/01_muestreo_EDU.R` reproduce todo el paso desde los archivos crudos hasta la lista ordenada, con `set.seed(2026)`.

1. Lectura de todos los lotes y conteo de registros leídos.
2. Deduplicación por UT.
3. Exclusión de registros cuyo DT incluye Review (Article; Review); se cuentan aparte (0 en esta exportación).
4. Control de PY (2025 o 2026) e idioma (English o Spanish); los registros fuera de rango se cuentan aparte (0 en esta exportación).
5. Exclusión de registros compartidos con otra área: se detectan por el campo WC (si el registro tiene alguna categoría de Salud o Computación/Ingeniería, pertenece también a ese universo, porque los demás filtros son idénticos). Opcionalmente se contrasta con los UT exportados por los otros equipos.
6. Orden aleatorio completo: el universo depurado se ordena por UT (para no depender del orden de exportación) y se permuta con semilla 2026. A03 = posición en esa lista.
7. Cuotas por estrato (año) con asignación proporcional y redondeo por mayor resto, sumando exactamente 300.

```
n_h = 300 \cdot \frac{N_h}{N}
```

Con asignación proporcional la muestra es autoponderada; los pesos N_h/n_h se calculan igual por script. Salidas: lista_ordenada_EDU.csv (incluye la columna A08_sugerido), cuotas_EDU.csv, flujo_EDU.csv (insumo del diagrama de flujo), lotes_EDU.csv y sessionInfo_EDU.txt.

7. Elegibilidad, reemplazo y asignación

Cada estrato se recorre en el orden de `pos_estrato` hasta completar su cuota de elegibles; ningún artículo se elige fuera de ese orden.

- Exclusiones: E1 (la IA generativa es el objeto de estudio), E2 (no es artículo original: protocolo, revisión clasificada como Article, ensayo sin datos), E3 (texto completo inaccesible tras acceso abierto, suscripción UCM y solicitud al autor), E4 (retractado). Se registra A05 = 0 y A06 con el motivo, y se pasa al siguiente del mismo estrato.
- E3 exige esperar la respuesta del autor: fijar un plazo (por ejemplo 10 días hábiles) antes de declarar inaccesible y reemplazar.
- Asignación: dentro de cada estrato, posiciones impares a MSC y pares a JPM (columna `A08_sugerido`), hasta 150 elegibles por estudiante. Si uno avanza más rápido, toma las posiciones siguientes del otro registrándolo en la bitácora.
- Machine learning como método del estudio no excluye ni cuenta como declaración de uso.

8. Decisiones abiertas

Estos puntos no los resuelve el enunciado; se deciden con el profesor o entre equipos y se anotan en la bitácora con fecha.

- ☑️ Registros de Educación que además están en Computer Science, Artificial Intelligence: cerrada, no hay ninguno en el universo final (0 de 85.611).
- ☐ Registros Article; Proceedings Paper y Article; Early Access: se mantienen (no son Review) salvo instrucción contraria. Hay 18 Proceedings Paper en el universo final; confirmar con el profesor.

- ☑️ Registros Early Access sin PY: cerrada, no existen en este universo.
- ☐ Lista común de UT compartidos entre áreas, para que los tres diagramas de flujo informen el mismo número. Abierta: hoy el cruce usa solo las categorías WC (5.574 registros compartidos eliminados).
- ☐ Plazo de espera para solicitudes al autor (E3). Abierta; el protocolo sugiere 10 días hábiles.

9. Repositorio y checklist E1

Repositorio del equipo: Metodologia-INV (GitHub), con un README que permite reproducir la lista desde la exportación de WoS. Hoy es público; pasarlo a privado queda pendiente.

```
Metodologia-INV/
├── README.md
├── R/01_muestreo_EDU.R
├── R/02_descarga_textos_EDU.R
├── R/03_seleccion_calibracion_EDU.R
├── data/raw/wos_edu/   # lotes WoS sin modificar
├── data/calibracion/   # selección y planillas de la calibración (E2)
├── output/             # lista, cuotas, flujo, lotes, sessionInfo
└── docs/               # protocolo, registro y bitácoras
```

- ☑️ Protocolo completo (este documento, v1.1, exportado a PDF en docs/protocolo_E1.pdf)
- ☐ Registro de búsqueda completo (sección 4). Parcial: faltan la consulta exacta, los ajustes de sintaxis y el N por año de la pantalla de WoS.
- ☑️ Universo exportado en data/raw/wos_edu/ (92 lotes, 91.185 registros únicos)
- ☑️ Script de muestreo ejecutado sin errores desde cero (Windows y Linux, misma lista)
- ☑️ lista_ordenada_EDU.csv, cuotas_EDU.csv, flujo_EDU.csv
- ☑️ Suma de lotes = N del registro de búsqueda (91.185)

10. Declaración de uso de IA

El enunciado exige declarar el uso de IA en las entregas con los criterios del libro de códigos (herramienta, versión, propósito, extensión, supervisión). Declaración vigente:

> *Durante la preparación de esta entrega se usó Claude (Anthropic) en octubre de 2026: Claude Opus 5.5 en el borrador inicial del protocolo (v1.0) y Claude Sonnet 5.5 (claude-sonnet-5-5, en Claude Code) entre el 14 y el 15 de octubre de 2026. El propósito fue redactar y actualizar el protocolo (v1.1) y la documentación de docs/, escribir y ampliar los scripts de muestreo (R/01_muestreo_EDU.R) y de selección de calibración (R/03_seleccion_calibracion_EDU.R), verificar que la lista se reproduce en Linux, apoyar la búsqueda de artículos de calibración en páginas de las editoriales y guiar los pasos de Git. Los autores revisaron, ejecutaron y editaron el contenido y asumen plena responsabilidad por él. La IA no se usó en la búsqueda en WoS ni en la exportación del universo. La codificación de artículos es exclusivamente humana; cualquier codificación asistida por IA se registra y declara por separado.*